2026腾讯游戏安全技术竞赛：三角洲GameGPT赛道
初赛技术文档与方案解析

参赛选手：ZZZ

2026年4月24日

摘要

针对三角洲 GameGPT 赛道“基于历史对局状态序列预测玩家短期最优决策”的任务，本技术报告提出并实现了一套基于深度结构化特征工程与 CatBoost 双模型集成的生成式决策预测框架。本方案深度解析了长达20秒、包含多智能体复杂交互的日志级数据，通过深入的数据挖掘与演进，构建了包含干员能力先验、时空轨迹动力学、高精度 Buff 文本挖掘、以及伤害-技能时序联动的332维超维特征体系。在工程实现上，配合高并发数据预处理流水线和 Parquet 列式缓存架构，单次全量特征重算耗时压缩至分钟级。在全量 28.9 万条训练数据上的分层五折交叉验证（Stratified 5-Fold CV）表明，本方案决策准确率达 99.54%，动作预测宏平均 F1 达 88.80%，赛方模拟综合得分高达 0.9732。本报告将全方位详述数据流向、超维特征体系的业务逻辑、预处理工程优化及后处理校准策略。

1 赛题分析与架构设计

1.1 任务难点深度剖析

本赛题要求利用 20 秒的“上文”信息（玩家坐标、血量、装备、视野等），预测未来 5 秒主玩家的宏观决策（交战/避战）和微观行为（救援、搜物资、开火、放技能、丢雷、开镜）。该任务在数据形态和业务逻辑上面临以下核心挑战：

1. **数据异构性与序列噪音：** 原始对局数据是以“帧”为单位的半结构化文本日志。每个样本包含数百乃至上千行事件记录，信息维度极不对齐（如坐标是连续浮点数，而“可见性”与“Buff”是复杂的嵌套中文字符串），需进行极强的信息抽取。

2. **因果延迟与时空依赖：** 玩家的战术决策具有显著的延迟效应。例如，3秒前受到远距离狙击、10秒前发现高价值物资或队友倒地，都会成为当前决策的隐性驱动力。

3. **长尾分布与类别极度不平衡：** 数据集的行为标签呈现典型的重尾分布。“开火”与“开镜”占据了绝大多数样本，而“救援”与“丢雷”属于极少数类。若直接采用单一的多分类器拟合，模型极易陷入局部最优，导致少数类完全崩塌。

4. **语义表现的模糊性：** 在游戏日志中，“丢雷”与“放技能”在系统底层的动作上报中高度相似，均可能伴随“前摇动作”和复杂的 Buff 生成，极易造成模型混淆。

1.2 总体 Pipeline 设计

鉴于时序生成任务的高昂成本与幻觉风险，本方案将复杂的时序预测任务转化为 **“超高维特征工程 + 强鲁棒梯度提升树 (GBDT)”** 的表征学习范式。 方案的 Pipeline 主要包含四大阶段：

- **Phase 1: 大规模数据解析与并发预处理** (Data Parsing & Preprocessing)
- **Phase 2: 深度特征工程** (Feature Extraction，构建332维特征空间)
- **Phase 3: 双路 CatBoost 联合训练** (Dual-Model Training)
- **Phase 4: 逻辑推演与物理规则校准** (Post-processing)

2 数据解析与工程预处理优化

在应对 10 万条级别的对局片段（总计达千万级日志行）时，纯文本的重复 I/O 和正则解析成为了限制模型迭代的最主要瓶颈。为此，本方案重构了底层的数据流，实现了工业级的离线预处理流水线。

2.1 原始日志序列的精细结构化

- **动态字段映射：** 将原始文本按管道符 `|` 切割。算法针对 17 字段和 20 字段版本的“玩家基础信息”设计了自适应解析逻辑，精准抽取空间坐标 (x, y, z)、欧拉角 (Yaw, Pitch, Roll) 以及速度向量 (v_x, v_y, v_z)。
- **可见性 (Visibility) 深度解析：** 日志中的视野遮挡数据为嵌套字符串。本方案构建了预编译的正则表达式 `r'(\d+) ([\d.]+)'`，将纯文本转化为结构化的元组列表 $(Target_ID, Visibility_Percentage)$，为提取视野内敌人数、最大暴露率奠定了基础。
- **主视角（Main Player）动态寻址与隔离：** 训练集通过标签行可明确定位主玩家，但测试集屏蔽了该行。本方案采用回溯策略，通过定位“游戏开始”事件中的首位玩家 ID 动态绑定主玩家。由此，所有坐标与事件均可以该主玩家为原点进行相对系转换。

2.2 大规模高并发处理与 Parquet 缓存机制

为实现特征工程的“敏捷迭代”，本方案开发了 `preprocess.py` 专用管道：

- **进程级异步并发 (Multiprocessing Pool)：** 采用 Python 的 `multiprocessing` 模块，挂载 64 个工作进程（`n_workers=64`），对文件目录树进行 Chunk 级（Chunk Size = 64）的分块异步读取与特征提取。该机制将 CPU 利用率拉满，使得 28.9 万条训练样本的解析耗时从数小时级压缩至 8 分钟内。
- **列式压缩存储 (Parquet Format)：** 抽取的 332 维特征矩阵被转化为 Pandas DataFrame 并统一持久化为 Parquet 格式（`train_features.parquet`）。相比传统 CSV，Parquet 采用列式存储与字典压缩，将几十 GB 的文本数据压缩至百兆级别，后续每次训练时的数据加载仅需 **0.7 秒**。

- **极速试错模式：** 预处理脚本支持 `--small N` 参数进行分层下采样（如每类只取 500 条），在构建特征新版本时，能够实现秒级的特征验证闭环。

3 超维深度特征工程

特征工程是本方案的核心壁垒。在持续的方案优化与特征迭代中，共计提炼出 **332 维** 高价值特征，全面覆盖了从宏观战局到微观肌肉记忆的各个层面。

3.1 宏观战局与干员能力先验库

模型首先需要具备“游戏常识”。本方案将《三角洲行动》的 13 位干员映射为抽象职能（Assault, Medic, Recon, Engineer 等）。

- **阵容倾向评估：** 提取 `has_medic`, `assault_ratio`。医疗兵比例高的队伍倾向于避战救援；突击兵比例高的队伍交战欲望更强。
- **技能 CD 时间戳建模：** 本方案硬编码了所有干员的战术技能 (V)、大招 (X) 及投掷物 (G) 的基础冷却时间。通过计算队伍平均 CD 及主玩家 `main_g_usable_in_20s`，模型在输入层便可知晓当前玩家“是否有条件”丢雷。

3.2 主玩家时空动力学与轨迹变异

本方案对主玩家在时间轴 $[t-20s, t]$ 上的轨迹数据进行了 0-7s, 7-14s, 14-20s 的精细分箱：

- **运动学导数特征：** 提取了主玩家在各个时间窗的合成速度 $\bar{v}$ 极值。特别是 **末段加速度**：

  $$Accel_{late} = \bar{V}_{[14s,20s]} - \bar{V}_{[7s,14s]}$$

  $Accel_{late}$ 的急剧下降往往意味着玩家找到了掩体并准备开镜对枪或救援，是极强的交战/避战分水岭。

- **Aiming 动力学 (Yaw/Pitch)：** 计算相邻帧的欧拉角一阶导数（视角变化率）。最后 5 秒内的高频 Yaw 变化（`main_late_yaw_max`）表征了玩家正在激烈地索敌或跟枪。
- **微操姿态关联 (Slide $\times$ Explosive)：** 经过数据挖掘，本报告发现了一条针对“红狼”、“威龙”等突击干员的黄金复合特征：

  $$F_{slide_exp} = N_{slides} \times N_{late_explosive_buffs}$$

  该特征将“滑铲次数”与“末段爆炸类 Buff”相乘，完美捕捉了高端玩家“滑铲突进+贴脸丢雷”的战术习惯。

3.3 战斗烈度与生存压力时序衰减

玩家的决策严重依赖于即时的生存反馈。

- **伤害爆发池：** 本方案不仅计算了 20 秒内的总输出/受击总量，还利用滑动窗口统计了瞬时最大伤害爆发率 `global_dmg_burst_1s_max`，并专门剥离出最后 3 秒的伤害值 `hp_damage_last3s`。末端骤增的伤害是开火反击的绝对信号。
- **死亡-救援因果链：** 本方案提取了 `has_recent_death` 特征（过去 10 秒内是否存在队友死亡）。在缺乏此特征时，模型极难预测“救援(BeingRescue)”，因为救援前玩家往往处于静止且无伤害状态，容易被误判为“搜物资”。

3.4 高精度自然语言 Buff 文本挖掘

这是区分“放技能”与“丢雷”的关键。由于“技能生效”事件中的 Buff 描述极度繁杂，正则模糊匹配效果甚微。 本方案构建了人工核验的 **精确匹配池 (Exact Matches)**：

- **爆炸类 (Explosive Exact)：** 涵盖“手炮爆炸导致耳鸣”、“铁丝网手雷减速”等。
- **技能类 (Skill Exact)：** 涵盖“肾上腺素:大招”、“侦察兵探测箭标记”等。

进而，本方案构造了核心鉴别器比值特征：

$$Ratio_{exp_vs_skill} = \frac{N_{explosive_exact}}{N_{explosive_exact} + N_{skill_exact} + \epsilon}$$

该特征直接在非线性树模型中划定了“丢雷”与“放技能”的决策超平面。

3.5 战术阶段软打分 (Phase Detection)

为了让模型获得类似人类专家的“战局大局观”，本方案利用启发式公式为当前时间切片进行软打分（Soft Score）：

$$\begin{aligned} Score_{Search} &= w_1 \cdot \tilde{N}_{items} + w_2 \cdot (1 - \tilde{V}_{avg}) + w_3 \cdot I_{(dmg=0)} \\ Score_{Fight} &= w_1 \cdot \tilde{N}_{dmg} + w_2 \cdot \tilde{\Delta}_{yaw} + w_3 \cdot \tilde{P}_{scope} \\ Score_{Retreat} &= w_1 \cdot \tilde{V}_{top} + w_2 \cdot I_{(\Delta dist>0)} + w_3 \cdot I_{(late_dmg=0)} \end{aligned}$$

这组连续特征极大地提升了二分类模型对宏观意图的感知度。

4 模型架构设计与物理规则校准

4.1 “意图-动作”双路联合架构

针对极端不平衡的数据标签，若训练单一的 6 分类模型，模型会不可避免地倾向于预测“开火”和“开镜”。 为此，本方案设计了双路 CatBoost 架构：

1. **Decision Model (二分类)：** 专注于预测宏观意图（交战 vs 避战）。迭代 2000 次，学习率 0.03，树深 8。损失函数采用 `auto_class_weights='Balanced'`，彻底抹平正负样本不均。

2. **Action Model (多分类)：** 专注于 6 大动作。采用 `TotalF1:average=Macro` 作为评价和早停指标，并引入 `SqrtBalanced` 对类权重进行平方根平滑，有效提振了少数类（救援、丢雷）的召回率。

4.2 逻辑推演与后处理校准 (Post-processing)

本报告在验证集的混淆矩阵中发现了部分语义冲突，因此在推理阶段植入了以下专家校验规则：

1. **长尾动作置信度抑制：** 验证发现，“丢雷”往往伴随技能释放，容易产生假阳性误报。本方案在推理逻辑中硬编码：若预测为丢雷但其概率 $P(Grenade) < 0.38$，则强制清零该项概率并回退至次优动作。

2. **多模态决策强行对齐：** 确保宏观意图与微观动作绝对自洽。若动作模型输出确信为交战类动作（开火、丢雷、技能、救援），无视二分类结果，强制设定 $Decision = 1$（交战）；若动推为“开镜”，强制修正决策为避战。

3. **高置信度意图反写动作：** 若多分类预测为最模糊的“搜物资”，但此时决策模型给出了极高的交战概率 ($P_{decision} > 0.72$)，则否决搜物资指令，强制提取动作概率矩阵中的“交战子集最大值”进行覆盖替换。此举完美融合了双模型的优势。

5 实验结果与多维评估

依托上述高效工程流水线与超维特征库，本方案在 289,199 条全量训练数据上（332 维特征）执行了严谨的 Stratified 5-Fold Cross Validation。

5.1 五折交叉验证得分 (OOF Metrics)

两组模型的验证指标均达到极高水准（如表1）。

表 1: 5折交叉验证评估指标 (Out-Of-Fold)

模型阶段	分类任务	Accuracy (准确率)	F1-Score
Decision Model	二分类 (交战/避战)	**0.9954**	**0.9945** (Macro)
Action Model	6-Class MultiClass	**0.9214**	**0.8880** (Macro)

根据赛事规程，综合得分按照 $Score = 0.7 \times Acc_{decision} + 0.3 \times Acc_{action}$ 计算。基于全量验证集的客观统计，**本方案的赛制模拟综合得分高达 0.9732**，展现出压倒性的预测精度。

5.2 混淆矩阵长尾流向分析

针对动作预测模型，本报告截取了全量 OOF 的归一化混淆矩阵数据进行深层分析：

- 大类表现极佳：“开镜”、“搜物资”、“救援”的召回率均超过了 98%。

- **“丢雷”与“技能”的边界碰撞：** 真实的丢雷样本中有 59.9% 被正确召回，但有 15.9% 被错判为开火，有 23.4% 被错判为使用技能。这从数据分布上直接印证了第 4.2 节中引入“丢雷抑制阈值 (0.38)”的绝对必要性——必须在推理端限制置信区间以对抗特征交叉污染。

5.3 核心驱动特征排名 (Top Feature Importance)

通过提取 CatBoost 模型的信息增益（Feature Importance），排名前十的核心判据如表2所示：

表 2: Decision Model 特征重要度排名 Top 10 (基尼重要性)

排名	特征物理意义 (Feature Name)	权重(%)	排名	特征物理意义 (Feature Name)	权重(%)
1	`n_unique_action_types` (微操丰富度)	12.64	6	`last_action_is_scope` (末帧是否开镜)	3.47
2	`last_n_scoped` (末端小队开镜总数)	5.14	7	`main_n_vis_frames` (主玩家视野活跃帧数)	3.30
3	`has_scope_action_last3s` (近3s开镜)	4.93	8	`n_reload` (换弹频率)	2.94
4	`n_slides` (滑铲频次)	4.48	9	`main_max_vis_targets` (瞬时最大可见敌人数)	2.76
5	`n_prone` (卧倒频次)	4.12	10	`main_last_scoped` (主玩家末帧开镜状态)	2.75

分析表明，能够最直观反映玩家交火意图的并非坐标距离，而是**微操繁杂度**与**开镜状态的时序突变**。这完全契合高水平 FPS 玩家“遇敌瞬间高频身法+秒开镜”的肌肉记忆逻辑。

5.4 未知测试集的泛化推断表现

在本方案中，针对初赛最终提供的 1000 条未知测试片段，模型从预处理到最终推理输出 Excel 的全流程耗时仅为 8.1 分钟。最终预测分布如下：

- **宏观意图：** 交战 504 题，避战 496 题（完全符合平衡大数定律）。
- **微观动作：** 开镜 388，开火 135，使用技能 322，搜物资 108，救援 34，丢雷 13。

这一分布完美重现了游戏实战中的战术行为频率先验，证明模型在面对泛化数据时没有出现任何单一类别的崩溃。

6 总结

在三角洲 GameGPT 初赛中，本方案直击序列日志数据时效性强、信息混杂的痛点。工程上，本方案搭建了进程级高并发与 Parquet 列式存储底座，消除了海量数据处理的 I/O 瓶颈；算法上，本方案萃取了深度融合游戏理解、物理运动学、时序衰减以及精准 NLP 匹配的 332 维超维特征。结合强鲁棒的 CatBoost 树模型与极具业务针对性的物理规则校准策略，本方案在近 30 万条实战数据上取得了 **0.9732** 的极高客观综合得分。本方案不仅在理论精度上具备统治力，其敏捷轻量的架构更展现了优异的工业级落地潜力。